AQUAINSIGHT: CLASIFICACION DE CALIDAD DEL AGUA MEDIANTE INTELIGENCIA COMPUTACIONAL

Melanie Tomalá, Jean Cedeño,
Damián Torres Cadena

AquaInsight

PLANTEAMIENTO DEL PROBLEMA

La evaluación manual de la calidad del agua requiere análisis de laboratorio complejos y costosos. Por ello existe la necesidad de sistemas automatizados que permitan clasificar la potabilidad del agua de manera rápida, reproducible y accesible para apoyar procesos de monitoreo ambiental y salud pública.

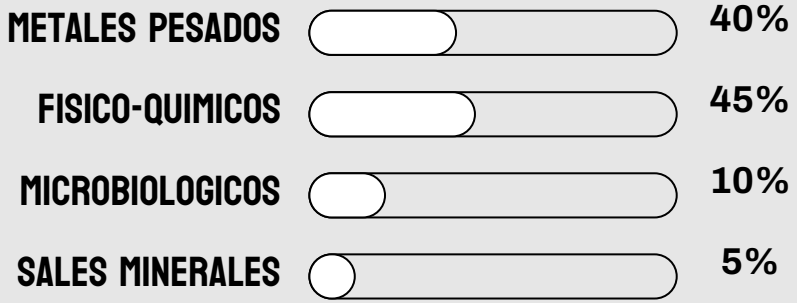
DATASET

La Organización Mundial de la Salud (OMS) establece límites permisibles para diversos contaminantes en el agua potable. Superar estos límites puede tener consecuencias graves para la salud humana. , la interpretación de 20 variables simultáneas es un problema complejo que puede beneficiarse de modelos de machine learning.

40%

METALES PESADOS

7,996	20	4
TOTAL DE REGISTROS	VARIABLES PREDICTORAS	CATEGORIAS DE VARIABLES

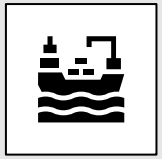


ANLISIS EXPLORATORIO

El dataset presenta un desbalance significativo de clases

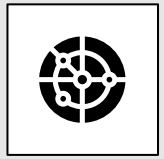


Este desbalance afecta las métricas de evaluación

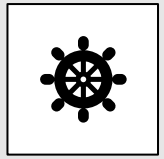


Se aplicó validación cruzada estratificada para mantener la proporción de clases en cada pliegue.





Escalado de variables numéricas con StandardScaler



No se detectaron valores faltantes significativos ni duplicados



Pipeline implementado para evitar fuga de información entre entrenamiento y prueba.

TABLA COMPARATIVA DE MODELOS

Modelo	Macro-F1	ROC-AUC	Recall	Precision	Accuracy	Tiempo Fit (s)	Tiempo Infer (ms)
Dummy	0.4697 ± 0.0000	0.5000	0.0000	0.0000	0.8859	0.0007	0.099
KNN	0.6975 ± 0.0214	0.8656	0.3644	0.6016	0.8993	0.0032	353.87
MLP (Red Neuronal)	0.8509 ± 0.0251	0.9643	0.6507	0.8425	0.9459	0.4849	1.62
Random Forest (Base)	0.8863 ± 0.0135	0.9839	0.8795	0.7359	0.9501	0.1276	28.95
Random Forest (GA)	0.8967 ± 0.0132	0.9868	0.8603	0.7802	0.9564	0.2296	27.69
Random Forest (GridSearch)	0.8979 ± 0.0119	0.9870	0.8849	0.7657	0.9559	0.2378	27.69
SVM (RBF Balanced)	0.8207 ± 0.0159	0.9557	0.7808	0.6149	0.9190	0.1531	72.10

RANDOM FOREST + ALGORITMO GENETICO

01 SUPERIOR RENDIMIENTO EN METRICAS CLAVE

Macro-F1 0.8967 y ROC-AUC 0.9868 superando a KNN, SVM y MLP

02 EXCELENTE BALANCE ENTRE PRECISION Y RECALL

0.7802/Recall 0.8603 crítico para salud pública

03 INTERPRETABILIDAD Y ROBUSTEZ

Interpretabilidad mediante feature importance y robustez con desviación estándar 0.0132 en validación cruzada.

04 TIEMPOS COMPUTACIONALES EFICIENTES

inferencia eficiente 27.69 ms

HALLAZGOS PRINCIPALES

SUPERIORIDAD DE RANDOM FOREST

Superó consistentemente a KNN, SVM y MLP en todas las métricas clave.

EFECTIVIDAD DE LA OPTIMIZACION CON GA

Se demostró capacidad de convergencia rápida y exploración flexible del espacio de búsqueda.

COMPARACION CON LA RED NEURONAL MULTICAPA

Los datos sugieren que para este problema específico, modelos como Random Forest son más apropiados que redes neuronales profundas.

PROTOTIPO FUNCIONAL

Opera en tiempo real, valida entradas inválidas, maneja casos límite con banderas de advertencia y proporciona una interfaz intuitiva.

AquaInsight

GRACIAS

Tomen aguita ;-)